

## MTH2302: Estimation

Wissem Maazoun

École Polytechnique de Montréal

Département de Mathématiques et de génie industriel

### Introduction

L'inférence statistique comprend l'estimation et les tests d'hypothèses (chap. 11). L'estimation d'un paramètre consiste à déterminer une statistique qui "réflète" autant que possible la vraie valeur (inconnue) de ce paramètre. Deux méthodes d'estimations sont possibles : l'estimation ponctuelle et l'estimation par intervalle de confiance.

## Estimation ponctuelle

### Définition

Soit  $X$  une v.a. dont la distribution dépend d'un paramètre  $\theta$  (ex.  $\text{Exp}(\lambda)$ ,  $\text{Poisson}(\lambda)$ , etc.), et soit  $X_1, X_2, \dots, X_n$  un échantillon **aléatoire** de  $X$ . Un estimateur ponctuel de  $\theta$  est une statistique  $\hat{\theta}$  de la forme  $\hat{\theta} = h(X_1, \dots, X_n)$ , vérifiant certaines propriétés.

### Exemples

- Pour estimer une moyenne  $\mu = E(X)$  d'une v.a.  $X$ , on peut utiliser  $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$ .
- Pour estimer une variance  $\sigma^2 = V(X)$  d'une v.a.  $X$ , on peut utiliser la variance de l'échantillon  $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$ .

## Propriétés d'un estimateur

### Critère 1 : Le biais

Le biais d'un estimateur  $\hat{\theta}$  d'un paramètre  $\theta$  est défini par

$$\text{Biais}(\hat{\theta}) = E(\hat{\theta}) - \theta.$$

On dit que l'estimateur  $\hat{\theta}$  est sans biais (ou non biaisé) pour  $\theta$  si  $\text{Biais}(\hat{\theta}) = 0$ , c-à-d si  $E(\hat{\theta}) = \theta$ .

### Exemples

- $E(\bar{X}) = \mu$ , donc  $\bar{X}$  est un estimateur sans biais de  $\mu$ .
- $E(\hat{p}) = p$ , donc  $\hat{p}$  est un estimateur sans biais de  $p$  la probabilité de succès.
- $E(S^2) = \sigma^2$ , donc  $S^2$  est un estimateur sans biais de  $\sigma^2$ .

## Propriétés d'un estimateur

### Critère 2 : L'erreur quadratique moyenne (EQM)

On mesure la précision globale d'un estimateur par son erreur quadratique moyenne. Soit  $\hat{\theta}$  un estimateur d'un paramètre  $\theta$ . On définit l'erreur quadratique moyenne de  $\hat{\theta}$  par

$$\text{EQM}(\hat{\theta}) = E(\hat{\theta} - \theta)^2.$$

On a toujours  $\text{EQM}(\hat{\theta}) = V(\hat{\theta}) + [\text{Biais}(\hat{\theta})]^2$ .

Lorsque  $\hat{\theta}$  est sans biais pour  $\theta$ , on a  
 $\text{Biais}(\hat{\theta}) = 0$  et  $\text{EQM}(\hat{\theta}) = V(\hat{\theta})$ .

Le critère de l'erreur quadratique moyenne permet de comparer les estimateurs d'un même paramètre. Ainsi, si  $\hat{\theta}_1$  et  $\hat{\theta}_2$  sont deux estimateurs d'un paramètre  $\theta$ , le plus efficace des deux est celui ayant la plus petite erreur quadratique moyenne.

$\hat{\theta}_1$  est plus efficace que  $\hat{\theta}_2$  si  $\text{EQM}(\hat{\theta}_1) < \text{EQM}(\hat{\theta}_2)$ .

## Propriétés d'un estimateur

### Exemple

Soit  $X_1, X_2, \dots, X_5$  un échantillon aléatoire d'une v.a.  $X$  telle que  $E(X) = \mu$  et  $V(X) = \sigma^2$ . Pour estimer  $\mu$ , on considère

$$\hat{\mu}_1 = \frac{X_1 + \dots + X_5}{5} \text{ et } \hat{\mu}_2 = \frac{2X_1 - X_2 + X_4}{2}.$$

- ➊  $\hat{\mu}_1$  et  $\hat{\mu}_2$  sont-ils sans biais ?
- ➋ Quel est le meilleur des deux ? Justifiez.

## Propriétés d'un estimateur

### Critère 3 : La convergence

Un estimateur  $\hat{\theta}_n$  de  $\theta$ , calculé sur un échantillon de taille  $n$  est dit convergent si lorsque  $n \rightarrow \infty$ , la probabilité que  $\hat{\theta}_n$  soit proche de  $\theta$  devient grande.

$$\forall \epsilon > 0, \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \epsilon) = 1.$$

Une condition suffisante pour la convergence de  $\hat{\theta}_n$  est que son erreur quadratique moyenne tende vers zéro lorsque  $n \rightarrow \infty$ .

### Exemple

Soit  $X_1, X_2, \dots, X_n$  un échantillon aléatoire d'une v.a.  $X$  telle que  $E(X) = \mu$  et  $V(X) = \sigma^2$ . Pour estimer  $\mu$ , on considère  $\hat{\mu} = \bar{X}$ . On a  $E(\bar{X}) = \mu$  et  $V(\bar{X}) = \frac{\sigma^2}{n} \rightarrow 0$  lorsque  $n \rightarrow \infty$ .  $\bar{X}$  est donc un estimateur convergent de  $\mu$ .

## Estimation ponctuelle

### Méthode des moments

Nous remarquons que la plupart des lois vues aux chapitres 5, 6 et 7, sont entièrement définies par un ou deux paramètres. Ces paramètres sont généralement liés aux deux premiers moments de la v.a. On peut citer par exemple :

Loi	Paramètres
Bernouilli	1 <sup>er</sup> moment
Géométrique	1 <sup>er</sup> moment
Poisson	1 <sup>er</sup> moment
Normale	Les deux premiers moments
Lognormale	Les deux premiers moments du logarithme
Exponentielle	Inverse du 1 <sup>er</sup> moment
Beta	2 paramètres fonctions des 2 premiers moments

## Méthode des moments

### Utilisation

Soit  $X$  est une v.a. continue ayant comme fonction de densité  $f(x, \theta_1, \theta_2)$ , ou une v.a discrète dont la fonction de masse est  $p(x, \theta_1, \theta_2)$  et que cette v.a est définie à partir de ces deux premiers moments qui nous sont inconnus. Si  $X_1, X_2, \dots, X_n$  est un échantillon aléatoire de taille  $n$  des valeurs de la v.a.  $X$ , on peut alors définir les deux premiers moments de cet échantillon par rapport à l'origine par :

$$m'_i = \frac{1}{n} \sum_{j=1}^n X_j^i, \quad i = 1, 2.$$

Ainsi, on peut estimer  $\theta_i$  par résolution du système

$$E[X^i] = m'_i, i = 1, 2.$$

### Méthode du maximum de la vraisemblance

La méthode de maximum de la vraisemblance est l'une des meilleures méthodes d'estimation ponctuelle. Soit  $X$  une v.a. ayant comme fonction de probabilité  $f(x, \theta)$  où  $\theta$  représente un paramètre inconnu. Si  $x_1, x_2, \dots, x_n$  est un échantillon de taille  $n$  des valeurs de la v.a.  $X$ , la fonction de vraisemblance de cet échantillon est alors :

$$L(\theta) = \prod_{i=1}^n f(x_i, \theta).$$

$\hat{\theta}$  l'estimateur du maximum de la vraisemblance de  $\theta$  consiste à la valeur de  $\theta$  telle que  $L(\theta)$  est maximale. Il s'agit essentiellement de la valeur de  $\theta$  qui maximise la probabilité d'obtenir les résultats fournis par l'échantillon.

### Exemples

- ➊ Déterminer l'estimateur du paramètre de la loi de Poisson.
- ➋ Déterminer l'estimateur du paramètre de la loi exponentielles.
- ➌ Déterminer l'estimateur des paramètres de la loi normale.

### Estimation par intervalle de confiance

#### Généralités

La méthode d'estimation d'un paramètre  $\theta$  par intervalle de confiance consiste à déterminer deux statistiques  $L(X_1, \dots, X_n)$  et  $U(X_1, \dots, X_n)$  vérifiant l'égalité  $P(L \leq \theta \leq U) = 1 - \alpha$ . On l'appelle le niveau (ou le coefficient) de confiance. On le choisit généralement proche de 1. Généralement les bornes  $L$  et  $U$  s'obtiennent en posant  $P(\theta < L) = \alpha/2$  et  $P(\theta > U) = \alpha/2$ . On obtient ainsi des intervalles de petite longueur (et généralement symétrique).

La méthode générale pour obtenir  $L$  et  $U$  consiste à considérer un estimateur  $\hat{\theta}$  de  $\theta$  et une fonction  $H(\hat{\theta}, \theta)$  dont la distribution ne dépend d'aucun paramètre inconnu (fonction pivotale). On peut alors trouver deux nombres  $h_1$  et  $h_2$  vérifiant

$$P(h_1 \leq H(\hat{\theta}, \theta) \leq h_2) = 1 - \alpha.$$

La forme exacte d'un intervalle de confiance dépend du paramètre à estimer et de la distribution de la variable considérée.

## Estimation par intervalle de confiance

### Intervalle de confiance pour une moyenne

Soit  $X$  une v.a de moyenne  $\mu$  et de variance  $\sigma^2$  et soit  $X_1, \dots, X_n$  un échantillon aléatoire de taille  $n$  de  $X$ . Pour un niveau de confiance  $1 - \alpha$  donné, les intervalles de confiance pour  $\mu$  sont résumés dans le tableau suivant différentes situations (tableau I.C. P262).

Une moyenne $\mu$		
$\sigma^2$ est connue et $X \sim N(\mu, \sigma^2)$ , ou $n$ grand	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$	$\mu \in \bar{X} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$
$\sigma^2$ est inconnue et $X \sim N(\mu, \sigma^2)$	$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim T_{n-1}$	$\mu \in \bar{X} \pm t_{\alpha/2; n-1} \cdot \frac{S}{\sqrt{n}}$
$\sigma^2$ est inconnue et $n$ est très grand	$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim N(0, 1)$	$\mu \in \bar{X} \pm z_{\alpha/2} \cdot \frac{S}{\sqrt{n}}$

## Estimation par intervalle de confiance

### Remarques

- Les intervalles donnés dans le tableau sont dits bilatéraux et symétriques. Pour un niveau  $1 - \alpha$  fixé, les intervalles du tableau sont les plus courts. De plus, lorsque  $n$  augmente, la longueur de l'intervalle diminue et la précision augmente.
- Les intervalles de confiance unilatéraux de niveau  $1 - \alpha$  se déduisent de ceux du tableau en considérant une seule borne de l'intervalle et en remplaçant  $\alpha/2$  par  $\alpha$ .
- Taille d'échantillon nécessaire : L'erreur d'estimation dans un intervalle de confiance pour  $\mu$  est de  $|\bar{X} - \mu|$ . Lorsque la variance  $\sigma^2$  est connue, on peut déterminer une taille d'échantillon nécessaire garantissant une erreur d'estimation d'au plus  $E$ , pour un niveau de confiance  $1 - \alpha$  donné.  
Lorsque  $E$  est fixé, on doit avoir  
 $|\bar{X} - \mu| \leq z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq E \Rightarrow n \geq (z_{\alpha/2} \frac{\sigma}{E})^2$ .



## Estimation par intervalle de confiance

### Remarques (suite)

- Dans le cas où la variance  $\sigma^2$  est inconnue, on remplace  $\sigma$  par l'écart type  $s$  de l'échantillon. Cette procédure est valide si  $X$  suit une loi normale (on a alors une loi  $T$  de Student à  $\nu = n - 1$  d.d.l), ou si  $n$  est grand on a alors une loi normale.

### Exemple

Le poids  $X$  des contenants d'un certain produit est une v.a de moyenne  $\mu$  et d'écart type 0,3 grammes. Un échantillon aléatoire de 100 contenants est choisi et donne une moyenne de 49,7 grammes. Construire un I.C. pour  $\mu$  de niveau

- ①  $1 - \alpha = 0,95$
- ②  $1 - \alpha = 0,99$
- ③ Quelle taille d'échantillon doit-on prélever pour que l'erreur d'estimation soit d'au plus 0,04 au niveau de confiance  $1 - \alpha = 0,90$ .



## Estimation par intervalle de confiance

### Exemple

Un certain procédé est utilisé pour la production en série de pièces dont le poids  $X$  peut être approché par une distribution normale  $N(\mu, \sigma^2)$ . Un échantillon de 5 pièces prises au hasard dans la production du procédé est examiné et les poids suivants sont observés :

45,7 46,0 46,8 45,2 46,3 (en grammes)

- ➊ Donner une estimation ponctuelle de  $\mu$ .
- ➋ Donner un I.C. pour  $\mu$  au niveau de confiance 90%.
- ➌ Donner un I.C. unilatéral (avec borne supérieure) pour  $\mu$  au niveau de confiance 90%.

## Estimation par intervalle de confiance

### Intervalle de confiance pour une variance $\sigma^2$

Soit  $X$  une v.a de loi  $N(\mu, \sigma^2)$ , avec  $\sigma^2$  inconnue, et soit  $X_1, \dots, X_n$  un échantillon aléatoire de  $X$ . Pour un niveau de confiance  $1 - \alpha$  fixé, l'I.C bilatéral de  $\sigma^2$  est

$$\frac{(n-1)S^2}{\chi_{\alpha/2; n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2; n-1}^2}$$

Une variance $\sigma^2$		
$X \sim N(\mu, \sigma^2)$ et $\mu, \sigma^2$ sont inconnues	$(n-1)\frac{S^2}{\sigma^2} \sim \chi_{n-1}^2$	$\frac{(n-1)S^2}{\chi_{\alpha/2; n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2; n-1}^2}$
Cas approximatif		
$n$ est grand ( $n \geq 40$ )	$\frac{S - \sigma}{\sigma/\sqrt{2n}} \sim N(0, 1)$	$\frac{S}{1 + \frac{z_{\alpha/2}}{\sqrt{2n}}} \leq \sigma \leq \frac{S}{1 - \frac{z_{\alpha/2}}{\sqrt{2n}}}$

## Estimation par intervalle de confiance

### Remarques

Les I.C unilatéraux de niveau  $1 - \alpha$  pour  $\sigma^2$  sont

- $\frac{(n-1)S^2}{\chi_{\alpha; n-1}^2} \leq \sigma^2$
- $\sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha; n-1}^2}$ .

- Lorsque  $X$  n'est pas distribuée selon une loi normale, on peut utiliser l'approximation suivante si la taille d'échantillon est grande ( $n \geq 40$ ) :  $S \sim N(\sigma, \frac{\sigma^2}{2n})$ .

On en déduit que pour un niveau de confiance  $1 - \alpha$  fixé, un intervalle de confiance pour  $\sigma$  est

$$\frac{S}{1 + \frac{z_{\alpha/2}}{\sqrt{2n}}} \leq \sigma \leq \frac{S}{1 - \frac{z_{\alpha/2}}{\sqrt{2n}}}.$$

## Estimation par intervalle de confiance

### Intervalle de confiance pour une proportion $p$

Soit  $p$  la proportion de "succès" dans une population et soit  $\hat{p}$  la proportion de "succès" dans un échantillon aléatoire de taille  $n$ . Pour un niveau  $1 - \alpha$  fixé, un I.C (approximatif) pour  $p$  lorsque  $n$  est grand est :

$$\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \leq p \leq \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}.$$

Une proportion $p$ $X \sim \text{Bernoulli}(p)$		
et $n$ est très grand	$\sqrt{\frac{\hat{p} - p}{p(1 - p)}} \sim N(0, 1)$	$p = \hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$

## Estimation par intervalle de confiance

### Remarques

- ① Les I.C unilatéraux de niveau  $1 - \alpha$  pour  $p$  se déduisent de celui du tableau en considérant une seule borne de l'intervalle et en remplaçant  $\alpha/2$  par  $\alpha$ .

- $\hat{p} - z_\alpha \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \leq p$
- $p \leq \hat{p} + z_\alpha \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$

- ② L'erreur d'estimation dans un I.C pour  $p$  est de  $|\hat{p} - p|$ . On peut déterminer une taille d'échantillon nécessaire garantissant une erreur d'estimation d'au plus  $E$ , pour un niveau de confiance  $1 - \alpha$  donné. On doit avoir

$$|\hat{p} - p| \leq z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \leq E \implies n \geq \left(\frac{z_{\alpha/2}}{E}\right)^2 p(1 - p)$$

- ① On dispose d'une estimation antérieure  $\hat{p}_0$  de  $p$ , on prend  $n \geq \left(\frac{z_{\alpha/2}}{E}\right)^2 \hat{p}_0(1 - \hat{p}_0)$ .
- ② On ne dispose d'aucune information sur  $p$ , on prend  $p = 0,5$ , et  $n \geq \left(\frac{z_{\alpha/2}}{E}\right)^2 \frac{1}{4}$ .

## Estimation par intervalle de confiance (deux échantillons)

### I.C pour une différence de deux moyennes $\mu_1 - \mu_2$

Soit  $X_1$  et  $X_2$  deux v.a (populations) de moyennes  $\mu_1$  et  $\mu_2$  et de variances  $\sigma_1^2$  et  $\sigma_2^2$  respectivement; et soient  $X_{11}, \dots, X_{1n_1}$  et  $X_{21}, \dots, X_{2n_2}$  deux échantillons indépendants provenants de  $X_1$  et  $X_2$  respectivement.

Notons  $\bar{X}_1$  et  $S_1^2$  la moyenne et la variance de l'échantillon 1, et  $\bar{X}_2$  et  $S_2^2$  la moyenne et la variance de l'échantillon 2.

Pour un niveau de confiance  $1 - \alpha$  donné, les intervalles de confiance pour la différence  $\mu_1 - \mu_2$  sont résumés dans le tableau suivant différentes situations.

## Estimation par intervalle de confiance (deux échantillons)

Situation	Loi utilisée	Intervalle
Une différence $\mu_1 - \mu_2$ $\sigma_1^2$ et $\sigma_2^2$ connues et $X_i \sim N(\mu_i, \sigma_i^2)$ , $i = 1, 2$ ou alors $n_1$ et $n_2$ grands	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$	$(\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \cdot \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
$\sigma_1^2$ et $\sigma_2^2$ inconnues avec $\sigma_1^2 = \sigma_2^2 = \sigma^2$ et $X_i \sim N(\mu_i, \sigma^2)$ , $i = 1, 2$	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim T_{n_1+n_2-2}$ où $S_p = \sqrt{\frac{(n_1-1)\bar{S}_1^2 + (n_2-1)\bar{S}_2^2}{n_1+n_2-2}}$	$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2; n_1+n_2-2} \cdot S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$
$\sigma_1^2$ et $\sigma_2^2$ inconnues avec $\sigma_1^2 \neq \sigma_2^2$ et $X_i \sim N(\mu_i, \sigma_i^2)$ , $i = 1, 2$	$\frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{\sqrt{\frac{\bar{S}_1^2}{n_1} + \frac{\bar{S}_2^2}{n_2}}} \sim T_\nu$ où $\nu = \frac{(\bar{S}_1^2/n_1 + \bar{S}_2^2/n_2)^2}{\frac{(\bar{S}_1^2/n_1)^2}{n_1-1} + \frac{(\bar{S}_2^2/n_2)^2}{n_2-1}} - 2$	$(\bar{X}_1 - \bar{X}_2) \pm t_{\alpha/2; \nu} \cdot \sqrt{\frac{\bar{S}_1^2}{n_1} + \frac{\bar{S}_2^2}{n_2}}$
$\sigma_1^2$ et $\sigma_2^2$ inconnues et $n_1, n_2$ grands ( $n_1 \geq 30, n_2 \geq 30$ ) Observations couplées $D = X_1 - X_2 \sim \text{Normale}$ $D_j = X_{1j} - X_{2j}, j = 1, \dots, n$	$\frac{\bar{D} - (\mu_1 - \mu_2)}{S_D / \sqrt{n}} \sim T_{n-1}$ où $\bar{D} = \frac{1}{n} \sum_{j=1}^n D_j, S_D = \sqrt{\frac{1}{n-1} \sum_{j=1}^n (D_j - \bar{D})^2}$	$\bar{D} \pm t_{\alpha/2; n-1} \cdot \frac{S_D}{\sqrt{n}}$

## Estimation par intervalle de confiance (deux échantillons)

### Remarques

- ❶ Les intervalles donnés dans le tableau sont dits bilatéraux et symétriques. Pour un niveau de confiance  $1 - \alpha$  fixé, les intervalles du tableau sont plus courts. Les intervalles unilatéraux de niveau  $1 - \alpha$  se déduisent de ceux du tableau en considérant une seule borne de l'intervalle et en remplaçant  $\alpha/2$  par  $\alpha$ .
- ❷ L'erreur d'estimation dans un intervalle de confiance pour la différence  $\mu_1 - \mu_2$  est de  $|\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)|$ . Lorsque les variances  $\sigma_1^2$  et  $\sigma_2^2$  sont connues, on peut déterminer une taille d'échantillon nécessaire  $n$  (la même pour les deux échantillons) garantissant une erreur d'estimation d'au plus  $E$ , pour un niveau de confiance  $1 - \alpha$  donné. En effet, si  $n_1 = n_2 = n$ , on a  $|\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)| \leq \frac{z_{\alpha/2}}{\sqrt{n}} \times \sqrt{\sigma_1^2 + \sigma_2^2} \leq E \implies n \geq \left( \frac{z_{\alpha/2}}{E} \times \sqrt{\sigma_1^2 + \sigma_2^2} \right)^2$ .

## Estimation par intervalle de confiance (deux échantillons)

### Exemple

Une analyse statistique descriptive des données sur des mesures de diamètre (en cm) des pièces produites par deux chaînes de production (A et B) a donné les résultats suivants :

Chaîne	A	B
nombre d'observations	51	51
moyenne : $\bar{x}$	1, 375147	1, 374982
écart-type : $s$	0, 000167	0, 000172

Soit  $X_1$  ( $X_2$ ) le diamètre des pièces produites par la chaîne A (B).  $E(X_1) = \mu_1, E(X_2) = \mu_2, V(X_1) = \sigma_1^2, V(X_2) = \sigma_2^2$ .

- ❶ Donner un intervalle de confiance pour  $\mu_1 - \mu_2$  au niveau de confiance 95%.
- ❷ Donner un intervalle de confiance unilatéral (avec borne inférieure) pour  $\mu_1 - \mu_2$  au niveau de confiance 95%.

## Estimation par intervalle de confiance (deux échantillons)

### I.C pour un rapport de deux variances $\sigma_1^2/\sigma_2^2$

Soit  $X_1$  et  $X_2$  deux v.a telles que  $X_1 \sim N(\mu_1, \sigma_1^2)$  et  $X_2 \sim N(\mu_2, \sigma_2^2)$ , et soit  $X_{11}, \dots, X_{1n_1}$  et  $X_{21}, \dots, X_{2n_2}$  deux échantillons indépendants provenant de  $X_1$  et  $X_2$  respectivement. Pour un niveau de confiance  $1 - \alpha$  donné, l'intervalle de confiance bilatéral pour le rapport  $\sigma_1^2/\sigma_2^2$  est

$$\frac{S_1^2}{S_2^2} F_{1-\alpha/2; n_2-1, n_1-1} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2} F_{\alpha/2; n_2-1, n_1-1}.$$

## Estimation par intervalle de confiance (deux échantillons)

### Exemple

On dispose de deux méthodes (A et B) pour la fabrication d'un produit. On s'intéresse au temps nécessaire pour fabriquer une unité du produit. Une analyse statistique descriptive a donné les résultats préliminaires suivants

Méthode	A	B
Taille d'échantillon	12	16
Écart-type $s$	0,85	0,98

Soit  $X_1$  ( $X_2$ ) le temps requis par le procédé A (B).

$X_1 \sim N(\mu_1, \sigma_1^2)$ ,  $X_2 \sim N(\mu_2, \sigma_2^2)$ .

- ① Donner un intervalle de confiance pour le rapport  $\frac{\sigma_1^2}{\sigma_2^2}$  au niveau de confiance  $1 - \alpha = 0,90$ .
- ② Donner un intervalle de confiance unilatéral (avec borne inférieure) pour le rapport  $\frac{\sigma_1^2}{\sigma_2^2}$  au niveau de confiance  $1 - \alpha = 0,90$ .

## Autres problèmes d'estimation par intervalle

### Les intervalles de prévision

Soit  $X_1, \dots, X_n$  un échantillon aléatoire d'une v.a  $X$  de loi normale  $N(\mu, \sigma^2)$ . On cherche parfois à prédire la future observation, disons  $X_{n+1}$  de  $X$ . On estime ponctuellement une telle observation par  $\bar{X}$ . Pour un niveau de confiance  $1 - \alpha$  fixé, l'intervalle de confiance pour  $X_{n+1}$  est

$$X_{n+1} \in \bar{X} \pm t_{\alpha/2; n-1} \sqrt{S^2(1 + \frac{1}{n})}.$$

Les intervalles unilatéraux de niveau  $1 - \alpha$  sont :

- $X_{n+1} \geq \bar{X} - t_{\alpha; n-1} \sqrt{S^2(1 + \frac{1}{n})}$ , cas unilatéral avec borne inférieure ;
- $X_{n+1} \leq \bar{X} + t_{\alpha; n-1} \sqrt{S^2(1 + \frac{1}{n})}$ , cas unilatéral avec borne supérieure.

**Exemple 10.27**

On a mesuré au cours de 10 vols l'accélération maximale (en g) d'un avion de ligne assurant une certaine liaison. Voici les résultats obtenus :

1,15 1,23 1,56 1,69 1,71 1,83 1,83 1,85 1,90 1,91

On a  $\bar{X} = 1,666$ ,  $s = 0,273$ . Donner un intervalle de prédiction de l'accélération maximale que l'avion subira lors de son prochain vol.

**Les intervalles de tolérance**

Un intervalle de tolérance (statistique) d'une v.a  $X$  est un intervalle calculé à partir des données d'un échantillon aléatoire  $X_1, \dots, X_n$  de  $X$ , qui contient (au moins) un pourcentage  $q$  (taux de couverture) des valeurs de  $X$ , avec une grande probabilité  $1 - \alpha$  (coefficients de confiance). On distingue deux méthodes selon que  $X$  suit une loi normale ou non.

**Les intervalles de tolérance****Cas où  $X$  suit une loi normale**

Lorsque  $X \sim N(\mu, \sigma^2)$ , il est démontré que l'intervalle de tolérance, avec un taux de couverture de  $q$  et un niveau de confiance  $1 - \alpha$  est de la forme

$$\bar{X} \pm k \times S.$$

$\bar{X}$  représente la moyenne de l'échantillon et  $S$  l'écart type. Les valeurs de  $k$  sont données dans la table **XIII** page 502 en fonction de  $q$ ,  $1 - \alpha$  et  $n$ .

**Remarque**

Les intervalles unilatéraux de tolérance sont de la forme  $\bar{X} - k \times S$  ou  $\bar{X} + k \times S$ . Les valeurs de  $k$  sont alors lues dans la table **XIII** page 501 en fonction de  $q$ ,  $1 - \alpha$  et  $n$ .

### Cas où $X$ suit une loi quelconque

Lorsque  $X$  est distribuée selon une loi quelconque mais de type continu, on considère

- $X_{\min} = X_{(1)} = \min\{X_1, \dots, X_n\}$
- $X_{\max} = X_{(n)} = \max\{X_1, \dots, X_n\}$

Il est alors démontré que  $[X_{\min}, X_{\max}]$  constitue un intervalle de tolérance pour la v.a  $X$ . Le taux de couverture  $q = P$  et le niveau de confiance  $1 - \alpha$  de cet intervalle sont tels que

$$1 - \alpha = 1 - nP^{n-1} + (n - 1)P^n.$$

On a donc deux possibilité

- ① Déterminer  $1 - \alpha$  lorsque  $P$  et  $n$  sont connus;
- ② Déterminer  $n$  approximativement, lorsque  $1 - \alpha$  et  $P$  sont connus, par  $n = \frac{1}{2} + \frac{1+P}{1-P} \frac{x_4^2(\alpha)}{4}$ .